

《人工智能与Python程序设计》—Numpy进阶知识补充




人工智能与Python程序设计 教研组



Python和Numpy进阶 知识补充

提纲



- ☐ Numpy数组的结构和索引操作
-

Numpy数组

- Numpy数组 (ndarray) 是Numpy库中最核心的数据类型
 - 支持对多维数组 (又叫张量 (Tensor)) 的高效存储和访问
 - 其结构如下:


```
In [3]: import numpy as np
x = np.arange(12).reshape((4,3))
print(type(x))
print(x)

<class 'numpy.ndarray'>
[[ 0  1  2]
 [ 3  4  5]
 [ 6  7  8]
 [ 9 10 11]]
```

a Data structure

x =

0	1	2
3	4	5
6	7	8
9	10	11



(from Array programming with NumPy, Nature volume 585, pages357–362(2020))

- 与python内置list不同:
 - 所有元素都是一个类型的, 由data type(x.dtype)决定
 - 数据保存在一段连续的内存空间中 (与C语言中数组类似)
 - 目的: 节省存储空间, 提升访问效率




Numpy数组

- Strides=(第1个轴的元素间隔字节; 第2个轴的元素间隔字节, ...))

```
>>> x1  
array([1, 2])  
>>> x1.strides  
(8,)
```

```
>>> x  
array([[ 1,  2,  3],  
       [ 4,  5,  6],  
       [ 7,  8,  9],  
       [10, 11, 12]])  
>>> x.strides  
(24, 8)
```

Numpy数组

- Strides=(第1个轴的元素间隔字节; 第2个轴的元素间隔字节, ...))

```
>>> y = np.random.rand(2,3,4)
>>> y
array([[ [0.36660593, 0.89192705, 0.78310747, 0.28450446],
         [0.72817003, 0.93904763, 0.3960034 , 0.59260957],
         [0.36612201, 0.32366565, 0.17590845, 0.1864782 ]],

        [[0.93648374, 0.3942387 , 0.58268292, 0.30826625],
         [0.69009674, 0.04729466, 0.75724622, 0.1421677 ],
         [0.36913801, 0.94732266, 0.94664117, 0.12232551]]])
>>> y.strides
(96, 32, 8)
```

96 = 3*4*8; 32=4*8; 8

索引|Numpy数组

- Numpy数组支持比Python内置list更为丰富的索引方式

- 索引一个元素:

`x[1,2]` → 5 with scalars

- 使用切片 (slice) 索引一块子区域:

`x[:,1:]` →

0	1	2
3	4	5
6	7	8
9	10	11

with **slices**

`x[:,::2]` →

0	1	2
3	4	5
6	7	8
9	10	11

with **slices**
with **steps**

Slices are **start:end:step**,
any of which can be left blank



ndarray 类的索引和切片方法

- 索引的方法: `x[dim1, dim2, ..., dimk, ..., dimn]`
- 不建议使用 `x[dim1][dim2] ...[dimk] ...[dimn]`: 效果不完全一样**

```
>>> x = np.random.rand(2,3,4)
>>> x
array([[[[0.90159864, 0.93219804, 0.17642648, 0.32082474],
        [0.57775284, 0.2158722 , 0.14507495, 0.84780954],
        [0.69937483, 0.1823171 , 0.03817363, 0.01213278]],

       [[0.70026162, 0.10048959, 0.21653884, 0.29747806],
        [0.51585691, 0.04687248, 0.38792813, 0.84652789],
        [0.89275589, 0.75414149, 0.04726253, 0.29301265]]]])
```

```
>>> x[0][1][2]
0.1450749491918859
>>> x[0,1,2]
0.1450749491918859
```

```
>>> x[:,1][:]
array([[0.70026162, 0.10048959, 0.21653884, 0.29747806],
       [0.51585691, 0.04687248, 0.38792813, 0.84652789],
       [0.89275589, 0.75414149, 0.04726253, 0.29301265]])
>>> x[:,1,:]
array([[0.57775284, 0.2158722 , 0.14507495, 0.84780954],
       [0.51585691, 0.04687248, 0.38792813, 0.84652789]])
```



ndarray 类的索引和切片方法

- 索引的方法: `x[dim1, dim2, ..., dimk, ..., dimn]`
- 不建议使用 `x[dim1][dim2] ...[dimk] ...[dimn]`: 效果不完全一样**

```
>>> x = np.random.rand(2,3,4)
>>> x
array([[[[0.90159864, 0.93219804, 0.17642648, 0.32082474],
         [0.57775284, 0.2158722 , 0.14507495, 0.84780954],
         [0.69937483, 0.1823171 , 0.03817363, 0.01213278]],

        [[0.70026162, 0.10048959, 0.21653884, 0.29747806],
         [0.51585691, 0.04687248, 0.38792813, 0.84652789],
         [0.89275589, 0.75414149, 0.04726253, 0.29301265]]]])
```

```
>>> x[:,1,1:2]
array([[0.2158722 ],
       [0.04687248]])
>>> x[:,][1][1:2]
array([[0.51585691, 0.04687248, 0.38792813, 0.84652789]])
```


回忆列表类的索引

- 只能使用 `x[dim1][dim2] ...[dimk] ...[dimn]`

```
>>> ls  
[[1, 2], [3, 4]]
```

```
>>> ls[1,3]  
Traceback (most recent call last):  
  File "<stdin>", line 1, in <module>  
TypeError: list indices must be integers or slices, not tuple
```

```
>>> ls[:]  
[[1, 2], [3, 4]]  
>>> ls[:][1:2]  
[[3, 4]]  
>>> ls[:][1:2][:]  
[[3, 4]]
```

索引|Numpy数组

- Numpy数组支持比Python内置list更为丰富的索引方式

- 按条件索引:

$x[x > 9] \rightarrow \boxed{10} \boxed{11}$ with **masks**

- 用数组作为数组的索引:

$x[\boxed{0} \boxed{1}, \boxed{1} \boxed{2}] \rightarrow [x[0,1], x[1,2]] \rightarrow \boxed{1} \boxed{5}$ with **arrays**



索引|Numpy数组

- Numpy数组支持比Python内置list更为丰富的索引方式
 - 用数组作为数组的索引:

```
# train / test split  
shuffled_index = np.random.permutation(data_size)  
x = x[shuffled_index]  
y = y[shuffled_index]
```



索引Numpy数组

- 更多例子

```
>>> import numpy as np
>>> x = np.arange(12).reshape((4,3))
>>> x
array([[ 0,  1,  2],
       [ 3,  4,  5],
       [ 6,  7,  8],
       [ 9, 10, 11]])
>>> x[::-1,::-1]
array([[11, 10,  9],
       [ 8,  7,  6],
       [ 5,  4,  3],
       [ 2,  1,  0]])
>>>
```

相当于进行了一次转置

```
>>> x
array([[ 0,  1,  2],
       [ 3,  4,  5],
       [ 6,  7,  8],
       [ 9, 10, 11]])
>>> x[2:3, -1]
array([ 8])
>>> x[-1, -1]
11
>>> x[-1]
array([ 9, 10, 11])
>>> x[:, -1]
array([ 2,  5,  8, 11])
>>> x[2:3]
array([[6, 7, 8]])
>>>
```




索引|Numpy数组

- 复合创建数组
 - Vstack (垂直堆叠)

```
import numpy as np
a = np.array([[1,2],[3,4]])
print 'First array:'
print a
print '\n'
b = np.array([[5,6],[7,8]])
print 'Second array:'
print b
print '\n'
print 'Vertical stacking:'
c = np.vstack((a,b))
print c
```

```
First array:
[[1 2]
 [3 4]]
Second array:
[[5 6]
 [7 8]]
Vertical stacking:
[[1 2]
 [3 4]
 [5 6]
 [7 8]]
```



索引|Numpy数组

- 复合创建数组
 - hstack (水平堆叠)

```
import numpy as np
a = np.array([[1,2],[3,4]])
print 'First array:'
print a
print '\n'
b = np.array([[5,6],[7,8]])
print 'Second array:'
print b
print '\n'
print 'Horizontal stacking:'
c = np.hstack((a,b))
print c
print '\n'
```

```
First array:
[[1 2]
 [3 4]]
Second array:
[[5 6]
 [7 8]]
Horizontal stacking:
[[1 2 5 6]
 [3 4 7 8]]
```

Numpy数组

- 对Numpy数组进行的操作和运算会自动的“向量化”(Vectorization)
 - 分别作用于Numpy数组中的每个元素


d Vectorization

0	1		1	1		1	2
3	4		1	1		4	5
6	7	+	1	1	→	7	8
9	10		1	1		10	11

Numpy数组

- 广播 (Broadcasting)
 - 通过“复制” d次, 将1维变成d维
 - 计算效率高于使用for循环依次计算
 - 以满足向量化计算的要求

e Broadcasting





Numpy数组

- 广播 (Broadcasting)
 - 通过“复制” d次, 将1维变成d维
 - 计算效率高于使用for循环依次计算
 - 以满足向量化计算的要求

```
>>> x
array([[1],
       [2],
       [3],
       [4]])
>>> y
array([5, 6])
```

```
>>> x * y
array([[ 5,  6],
       [10, 12],
       [15, 18],
       [20, 24]])
```

```
>>> x + y
array([[ 6,  7],
       [ 7,  8],
       [ 8,  9],
       [ 9, 10]])
```



Numpy数组

- 广播 (Broadcasting)

当运算中的 2 个数组的形状不同时，numpy 将自动触发广播机制。如：

实例

```
import numpy as np

a = np.array([[ 0, 0, 0],
              [10,10,10],
              [20,20,20],
              [30,30,30]])
b = np.array([1,2,3])
print(a + b)
```

运行结果会是什么？

Numpy数组

- 广播 (Broadcasting)

当运算中的 2 个数组的形状不同时，numpy 将自动触发广播机制。如：


实例

```
import numpy as np

a = np.array([[ 0,  0,  0],
              [10,10,10],
              [20,20,20],
              [30,30,30]])

b = np.array([1,2,3])
print(a + b)
```

```
[[ 1  2  3]
 [11 12 13]
 [21 22 23]
 [31 32 33]]
```



Numpy数组

- 规约 (Reduction)

- 通过求和、求平均数等运算，将d维缩减为1维
 - 以求和函数`np.sum`为例
 - 可以通过`axis`可选参数决定按照哪个维度进行计算
 - 默认`axis=None`，将所有元素求和

```
In [16]: np.sum(x)
```

```
Out[16]: 66
```


```
In [17]: np.sum(x, axis=0)
```

```
Out[17]: array([18, 22, 26])
```

```
In [18]: np.sum(x, axis=1)
```

```
Out[18]: array([ 3, 12, 21, 30])
```


f Reduction



补充知识

- 索引是否发生拷贝？
 - 设计思路：尽可能避免拷贝，以节省内存
 - 如果可能，索引操作会返回一个和原数组共享存储的视图 (view)
 - 否则则拷贝数据生成一个新的Numpy数组对象

b Indexing (view)



c Indexing (copy)

`x[1, 2]` → 5 with scalars `x[x > 9]` → [10 11] with masks

`x[[0, 1], [1, 2]]` → `[x[0, 1], x[1, 2]]` → [1 5] with arrays

`x[[1, 1], [0, 0]]` → `x[[1, 1], [0, 0]]` → [4 3; 7 6] with arrays with broadcasting

```
In [7]: x[:, ::2]
```

```
Out[7]: array([[ 0,  2],
               [ 3,  5],
               [ 6,  8],
               [ 9, 11]])
```


```
In [8]: x[:, ::2].strides
```

```
Out[8]: (24, 16)
```


补充知识

- 索引是否发生拷贝？
 - 设计思路：尽可能避免拷贝，以节省内存
 - 如果可能，索引操作会返回一个和原数组共享存储的视图 (view)
 - 否则则拷贝数据生成一个新的Numpy数组对象

b Indexing (view)



c Indexing (copy)





补充知识

- 索引是否发生拷贝？
 - 设计思路：尽可能避免拷贝，以节省内存
 - 如果可能，索引操作会返回一个和原数组共享存储的视图 (view)
 - 否则则拷贝数据生成一个新的Numpy数组对象
 - Strides=(第1个轴的元素间隔字节; 第2个轴的元素间隔字节, ...)**


```
>>> x
array([[ 1,  2,  3],
       [ 4,  5,  6],
       [ 7,  8,  9],
       [10, 11, 12]])
>>> x.strides
(24, 8)
```

```
>>> x[:, ::2]
array([[ 1,  3],
       [ 4,  6],
       [ 7,  9],
       [10, 12]])
>>> x[:, ::2].strides
(24, 16)
```




区别Python核心语法与第三方库

- 核心语法并不多，需要牢固掌握
 - 遇到困扰怎么办？
 - 搜索，强烈推荐stackoverflow
 - 想深入了解的同学也推荐阅读：
 - <https://docs.python.org/3/tutorial/index.html>
 - <https://docs.python.org/3/library/index.html>
 - <https://docs.python.org/3/reference/index.html>
- 第三方库琳琅满目：
 - turtle, numpy, torch等
 - 如何学习
 - 不要逐一背诵接口：要按照功能分类，记住最主要的一些功能（创建、索引等）
 - 要学会查表、查资料，没有一门课程能够把所有接口完全覆盖



谢谢！